

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Искусственный интеллект»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Программный проект на тему:

**Разработка системы генерации тифлокомментариев на основе
данных футбольных матчей**

Выполнил студент:

группы #МИИ243, 2 курса

Мясникова Ангелина Андреевна

Принял руководитель ВКР:

Дурыгин Олег Дмитриевич

Руководитель направления по исследованию данных

ПАО «Сбербанк»

Москва 2026

Содержание

Аннотация	4
Ключевые слова	4
1 Введение	5
2 Обзор литературы	8
2.1 Генерация комментариев по структурированным событиям	8
2.2 Спортивные новости и live text commentary	9
2.3 Спортивная суммаризация	10
2.4 Отбор значимых событий	11
2.5 Генерация текста по данным	12
2.6 Датасеты футбольных комментариев	13
2.7 Автоматический футбольный комментарий	13
2.8 Трекинг игроков и пространственный контекст	15
2.9 Обзорные работы и индустриальный контекст	15
2.10 Ограничения и вклад настоящей работы	16
3 Данные и предобработка	17
3.1 Источник данных	17
3.2 Стандартизация координат и направления атаки	18
3.3 Разметка зон поля	20
3.4 Фильтрация некорректных 360-кадров	20
3.5 Формирование признаков событий и эпизодов	22
4 Методология	23
4.1 Стратегии формирования эпизодов	23
4.2 Soft-разметка важности эпизодов	28
4.3 Модели отбора эпизодов	32

5	Эксперименты и результаты	36
5.1	Сравнение стратегий группировки	36
5.2	Распределение soft-labels	38
5.3	Качество моделей отбора	38
5.4	Оценка LLM-комментариев	40
5.5	Пользовательская оценка аудиокомментариев	42
6	Программный прототип	42
6.1	Структура проекта	42
6.2	Интерфейс просмотра событий	43
6.3	Сборка аудиодорожки	44
7	Заключение	45
	Список литературы	46
A	Словарь признаков	50
B	Примеры JSON-payloads для LLM	53
C	Системный промпт для генерации комментариев	65
D	Пример ответа LLM	68
E	Материалы ручного анализа тифлокомментариев	68

Аннотация

Работа посвящена разработке прототипа системы автоматической генерации русскоязычных тифлокомментариев к футбольному матчу на основе структурированных событийных данных StatsBomb. В отличие от видеоориентированных подходов, рассматриваемый прототип строит комментарий без доступа к видеоряду: входом служат JSON-события матча, включающие тип действия, временную метку, координаты, участников эпизода, исход действия и при наличии данные StatsBomb 360. Основное внимание уделяется не только генерации текста языковой моделью, но и подготовке входного представления: стандартизации координат с учётом смены сторон, фильтрации некорректных 360-кадров, построению компактных цепочек событий и отбору эпизодов, пригодных для озвучивания.

В работе предложен пайплайн, включающий предобработку данных, формирование нескольких стратегий группировки событий, эвристическую разметку важности эпизодов, обучение моделей отбора на 51 матче Евро-2024, генерацию комментариев через LLM и последующую сборку аудиодорожки с помощью Silero TTS. Экспериментальная часть сравнивает стратегии формирования эпизодов и модели отбора, а также оценивает форматную корректность и фактическую пригодность LLM-комментариев. Практический результат работы — воспроизводимый прототип, позволяющий получить структурированные JSON-комментарии и аудиодорожку для выбранных матчей.

Ключевые слова

Тифлокомментирование; аудиоописание; футбольные события; StatsBomb; StatsBomb 360; data-to-text generation; спортивная суммаризация; языковые модели; soft labels; CatBoost; Silero TTS.

1 Введение

Тифлокомментарий — это специальный формат аудиоописания, предназначенный для людей с нарушениями зрения. В спортивной трансляции он решает практическую задачу: передать слушателю, где находится мяч, кто выполняет действие и чем завершается эпизод. В отличие от обычного спортивного репортажа, такой комментарий не столько оценивает игру, сколько помогает слушателю представить происходящее на поле. Поэтому он должен быть кратким, нейтральным и опираться только на проверяемые факты: где мяч, кто действует и как меняется эпизод.

Актуальность задачи связана с тем, что доступность спортивных трансляций постепенно становится частью международной и российской практики. На международном уровне FIFA обеспечивала аудиодескриптивное комментирование для слепых и слабовидящих болельщиков во время Клубного чемпионата мира FIFA 2025 [1]. В европейском футболе развитие таких сервисов поддерживается CAFE (Centre for Access to Football in Europe): организация совместно с футбольными структурами продвигает обучение аудиодескриптивных комментаторов и внедрение сервиса для слепых и слабовидящих болельщиков [2]. В России также появляются инфраструктурные решения: приложение «Особый взгляд» предоставляет доступ к адаптированным аудиодорожкам и прямому тифлокомментированию, включая спортивные матчи [3, 4]; в российских футбольных материалах отмечается сотрудничество «Спартака», «Локомотива» и «Крыльев Советов» с этим приложением [5]. Кроме того, Okko развивает тифлокомментирование в спортивных трансляциях: сервис сообщает о запуске тифлокомментариев для ключевых матчей Лиги чемпионов и о дальнейшем расширении таких дорожек [6]. Всё это показывает, что задача автоматизации и масштабирования тифлокомментариев имеет не только исследовательскую, но и практическую социальную значимость.



Рисунок 1.1 – Использование устройства для прослушивания тифлокомментария во время спортивного мероприятия

Футбольный матч представляет собой сложный поток событий. Один матч содержит тысячи записей: передачи, приёмы мяча, ведение, давление, фолы, удары, стандарты, действия вратаря. Большая часть этих событий не требует отдельной реплики: если описывать каждое действие, комментарий станет перегруженным и непригодным для восприятия. Поэтому задача автоматического тифлокомментирования не сводится только к генерации текста. Перед генерацией необходимо решить задачу отбора: какие эпизоды стоит озвучивать, как объединять отдельные события в смысловые цепочки и какой контекст передавать языковой модели.

В данной работе рассматривается event-based постановка: система получает не видео, а структурированный журнал событий StatsBomb. Такой подход имеет несколько преимуществ. Во-первых, он дешевле и воспроизводимее мультимодального анализа видео. Во-вторых, многие факты уже представлены в структурированном виде: тип действия, координаты, игрок, исход передачи или удара. В-третьих, такой формат позволяет явно контролировать фактиче-

скую опору комментария и снижать риск галлюцинаций языковой модели.

Однако у событийных данных есть и ограничения. Координаты StatsBomb задаются в фиксированной системе поля, но команды меняют стороны во втором тайме. Значит, понятия «вперёд», «назад», «своя половина», «чужая штрафная» должны вычисляться относительно команды и периода. Кроме того, данные StatsBomb 360 иногда оказываются геометрически несогласованными с событием, поэтому требуется отдельная фильтрация таких кадров. Наконец, связанные события могут образовывать слишком длинные цепочки, которые неудобно передавать в LLM: модель начинает пересказывать поток действий вместо короткого комментария.

Цель работы — разработать и экспериментально исследовать прототип системы генерации русскоязычных тифлокомментариев к футбольным матчам по данным StatsBomb JSON.

Для достижения цели решаются следующие задачи:

- 1) изучить литературу по автоматическому аудиоописанию, генерации спортивных комментариев и data-to-text generation;
- 2) разработать процедуру стандартизации событий и координат с учётом смены сторон в таймах;
- 3) реализовать фильтрацию некорректных StatsBomb 360 кадров и визуальную проверку стандартизации;
- 4) предложить стратегии группировки событий в эпизоды и сравнить их по длине, стоимости и пригодности для LLM;
- 5) построить эвристическую soft-разметку важности эпизодов и обучить модели отбора;
- 6) сформировать LLM-payloads и системный промпт для генерации тифлокомментария;
- 7) оценить качество LLM-ответов и собрать аудиодорожку с помощью Silero TTS;

- 8) подготовить прототип визуального интерфейса для просмотра событий и результатов.

Новизна работы состоит в адаптации пайплайна генерации аудиоописаний к русскоязычному футбольному тифлокомментарию по event JSON без видеоряда, а также в экспериментальном сравнении нескольких стратегий формирования эпизодов и отбора комментариев на всех 51 матчах Евро-2024.

Дальнейшая структура работы следующая. В Разделе 2 приведён обзор литературы. В Разделе 3 описаны данные и стандартизация. В Разделе 4 формализуется пайплайн формирования эпизодов и отбора. В Разделе 5 приводятся эксперименты. В Разделе 6 описан программный прототип. В заключении сформулированы результаты и направления дальнейшей работы.

2 Обзор литературы

Обзор построен от наиболее близких к задаче работ к более общим. Сначала рассматриваются исследования, где комментарий строится по структурированным событиям или текстовым трансляциям без видео. Затем обсуждаются работы по спортивной суммаризации, отбору значимых событий и data-to-text generation. Далее переходим к конкретным датасетам, вопросам временного выравнивания и мультимодальным расширениям. В конце выделяются ограничения существующих подходов и обосновывается вклад настоящей работы.

2.1 Генерация комментариев по структурированным событиям

Одной из наиболее близких к поставленной задаче работ является [7], где авторы рассматривают генерацию комментариев по журналам событий киберспортивных матчей в League of Legends. Вход — структурированные игровые события с атрибутами; выход — текстовые комментарии в духе живого репор-

тажа. Работа примечательна тем, что видео здесь вообще отсутствует: всё, что доступно системе, — это последовательность записей о действиях игроков. Авторы показывают, что такого входа достаточно для осмысленной генерации, если правильно выбирать ключевые события и поддерживать связность повествования.

Эта постановка очень близка к задаче настоящей работы. StatsBomb JSON по своей структуре устроен аналогично: каждая запись описывает одно действие на поле, содержит тип события, время, пространственные координаты и дополнительные поля. Разница лишь в домене — футбол против киберспорта, — но методологически оба сценария относятся к одному классу задач. Ключевой вывод из [7]: структурированные события достаточно выразительны для комментария при условии, что вход нормализован и содержательно отфильтрован.

Несколько иной угол зрения предлагает работа [8], где исследуется генерация комментариев для гоночных игр на основе комбинации числовых параметров, текстовых описаний и визуальных признаков. Интересно, что авторы отдельно исследуют вклад каждой модальности и приходят к выводу: структурированные числовые данные и текст дают значительную часть полезного сигнала, тогда как визуальный канал улучшает результат, но не является незаменимым. Для настоящей работы это важно как косвенное подтверждение того, что event-based подход жизнеспособен сам по себе.

2.2 Спортивные новости и live text commentary

Другое направление, непосредственно связанное с задачей, — это построение спортивных новостей и коротких отчётов по текстовым лентам трансляции. В работе [9] авторы предлагают метод автоматического формирования матчевой новости из live text commentary: системы, которые в реальном времени выдают короткие текстовые сообщения о происходящем на поле. Задача сформулирована как extractive summarization: из потока сообщений нужно отобрать

наиболее информативные и собрать из них связный отчёт.

Ключевое наблюдение этой работы состоит в том, что простое объединение сообщений не работает: большинство из них либо дублируют информацию, либо содержат незначительные детали. Авторы предлагают использовать признаки, связанные с изменением счёта, временем матча и типом события, чтобы оценивать значимость фрагментов. Для настоящей работы это важно по двум причинам: во-первых, подход строится исключительно на текстовых данных; во-вторых, он явно разделяет задачи отбора и генерации, что соответствует архитектуре, выбранной в данной работе.

Продолжением этой линии является [10], где проблема content selection для спортивных новостей рассмотрена подробнее. Авторы анализируют, какие типы событий чаще попадают в итоговые отчёты и почему, выделяют признаки значимости и показывают, что хороший отбор контента влияет на итоговое качество текста сильнее, чем улучшение модели генерации. Этот вывод хорошо согласуется с практическим опытом работы над настоящим проектом: изменение правил фильтрации событий даёт более заметный эффект, чем перебор различных промптов.

2.3 Спортивная суммаризация

В работе [11] задача построения спортивных новостей по live text commentary рассматривается с другой стороны. Авторы критически анализируют качество существующих датасетов и показывают, что многие из них содержат шумную псевдоразметку, полученную автоматически. Это делает прямое обучение на таких данных проблематичным: модель учится воспроизводить артефакты разметки, а не реальные закономерности журналистского текста. В результате предлагаются методы очистки датасета и контроля качества пар «лента — новость».

Для настоящей работы это наблюдение особенно ценно. В задаче тифло-

комментирования размеченных пар «события — комментарий» практически не существует, тем более для русскоязычного контекста. Значит, рассчитывать на обучение с учителем на готовых парах не приходится. Это подталкивает к подходу, основанному на чётких правилах отбора событий и generation через языковую модель с тщательно подготовленным промптом.

Важным ресурсом в этом контексте является работа о Chinese sports summarization, где схожая задача решается для китайского языка. Авторы показывают, что текстовые данные трансляций, даже без видео, позволяют строить суммаризацию достаточного качества при условии хорошей нормализации входа. Кроме того, в работе обсуждаются проблемы, специфичные для нелатинских языков, — например, токенизация и морфологическая неоднозначность. Эти наблюдения актуальны и для русскоязычного тифлокомментирования.

2.4 Отбор значимых событий

В задаче тифлокомментирования отбор событий — не вспомогательный этап, а центральный. Большую часть матча составляют рутинные эпизоды: короткие пасы в центре поля, позиционное перемещение без мяча, неактивные фазы. Если комментировать всё подряд, слушатель окажется в информационном шуме. Если быть слишком избирательным — пропустит важные моменты.

Исследования по выделению значимых событий в спортивных данных [10, 9] формулируют ряд устойчивых критериев: изменение счёта, нахождение мяча в штрафной зоне, удары по воротам, стандартные положения, смена владения в опасной зоне. В работе рассматривается смежная задача — автоматическое распознавание событий из текста комментария, — и авторы показывают, какие типы действий чаще всего упоминаются в репортажах. Этот обратный анализ даёт полезные подсказки о том, что считается «комментируемым» в реальной практике.

Отдельную роль играет временная близость событий. Передача, приём и

удар — это не три независимых события, а единый эпизод атаки, и комментировать их стоит вместе. В работе [13] авторы специально выстраивают датасет с учётом группировки событий в эпизоды и показывают, что модели, обученные на эпизодах, генерируют более связный текст, чем модели, работающие с отдельными событиями. Именно поэтому в настоящей работе сделан акцент на построении окон контекста, а не на пообъектной обработке.

2.5 Генерация текста по данным

Задача data-to-text generation изучается в NLP достаточно давно и имеет хорошо разработанную методологию. Ранние работы [14] строили детерминированные шаблонные системы: каждому типу записи соответствовал набор заготовленных фраз с подстановкой значений. Такой подход прост в реализации и даёт предсказуемый результат, но плохо обобщается на разнообразные ситуации.

Позже появились нейросетевые подходы [15], где модель обучается преобразовывать таблицы или JSON-структуры в текст. Современные языковые модели делают этот переход ещё более плавным: при правильно составленном промпте они способны интерпретировать структурированные данные и генерировать по ним связные фразы без явного обучения на парах «вход — выход». Именно этот сценарий используется в данной работе, где языковая модель получает на вход заранее подготовленное окно событий и выдаёт короткий комментарий.

Принципиальное наблюдение из литературы по data-to-text [14, 15]: качество выходного текста в значительной мере определяется качеством входного представления. Если данные поданы с лишними полями, противоречивыми значениями или неверной ориентацией пространственных координат, модель либо игнорирует эти детали, либо воспроизводит ошибки. Для задачи тифлокомментирования это означает, что предобработка и стандартизация — не технический

ритуал, а содержательная часть решения.

2.6 Датасеты футбольных комментариев

Если посмотреть, что именно сейчас доступно в качестве обучающих ресурсов для футбольного комментария, картина получается неоднородной. Датасет SoccerNet-Echoes [16] представляет собой большую коллекцию аудиокomentarиев, выровненных с временными метками матчей. Он предназначен прежде всего для задач speech recognition и аудиогенерации, но косвенно полезен и для тифлокомментирования: данные показывают, какие типы эпизодов чаще всего достаиваются развёрнутого устного описания.

Датасет LFC [13] устроен иначе: в нём текстовые комментарии выровнены с координатами игроков из tracking data, что позволяет обучать и оценивать модели генерации на уровне отдельных эпизодов. Авторы специально сравнивают text-based и image-based представления футбольных событий и показывают, что текстовое кодирование позиций не уступает визуальному по итоговому качеству комментария. Это — прямое подтверждение того, что задача генерации тифлокомментария по событийным данным методологически состоятельна.

Открытые данные StatsBomb [17, 18] не являются датасетом комментариев в строгом смысле, но служат основным источником событийной информации в настоящей работе. Особенность формата — высокая детализация: по сравнению с другими открытыми источниками StatsBomb содержит данные о давлении, типах приёмов мяча, выборе зон на поле. Это делает его одним из наиболее информативных открытых форматов для футбольного анализа и удобным источником для построения тифлокомментариев.

2.7 Автоматический футбольный комментарий

Работа [19] рассматривает задачу автоматической генерации комментариев к футбольным матчам и делает особый акцент на проблеме temporal

alignment — то есть правильного соответствия между событием и моментом его описания. Авторы показывают, что даже небольшое рассогласование по времени заметно ухудшает воспринимаемое качество комментария. Кроме того, в работе сравниваются разные способы представления входных данных: текстовое описание событий, изображения поля и трекинг игроков.

Важный практический вывод [19]: при использовании только текстовых и координатных данных модель показывает результаты, сопоставимые с мультимодальными вариантами. Это ещё раз подтверждает, что видеопоток не является обязательным компонентом системы. При этом авторы особо отмечают необходимость стандартизации координат с учётом смены сторон — именно та проблема, которая оказывается нетривиальной в работе с данными StatsBomb.

Другая недавняя работа по Soccer Commentary Generation [20] исследует генерацию комментариев для highlight clips — коротких видеофрагментов ключевых моментов. Здесь на первый план выходит задача alignment’a: как связать момент ролика с правильным комментарием. Авторы отмечают, что именно выравнивание, а не качество генератора текста, является узким местом существующих подходов. Для настоящей работы это важное наблюдение: задача определения нужного момента для комментария оказывается нетривиальной даже при наличии развитых генеративных моделей.

В работе [21] предлагается подход к генерации комментариев с использованием knowledge-enhanced визуального рассуждения: система дополняет визуальное восприятие сцен фактическими знаниями о правилах игры, составе команд и статистике. Это интересный вектор развития, хотя для задачи тифлокомментирования существенно то, что и в этой работе событийные данные остаются основным источником структурной информации, а визуальный канал добавляет лишь дополнительный контекст.

Наиболее близкой к задаче аудиоописания футбольного матча является работа MCAD [22], где рассматривается multimodal context-aware audio description generation for soccer. В отличие от классического спортивного комментария,

MCAD ориентирована именно на описание сцены для пользователя, которому недостаточно одного видеоряда. Для настоящей работы эта постановка важна методологически: она подтверждает необходимость не только сгенерировать текст, но и выбрать момент, содержание и степень детализации описания. Отличие предлагаемого подхода состоит в том, что входом служит не видеопоток, а стандартизированный событийный JSON с координатами и 360-контекстом; это делает систему дешевле, воспроизводимее и применимой к открытым данным StatsBomb.

2.8 Трекинг игроков и пространственный контекст

Ряд работ рассматривает комментарий как задачу, в которой пространственная информация играет ключевую роль. В [23] используются данные трекинга игроков — точные траектории перемещения на поле — для генерации более точных пространственных описаний. Авторы показывают, что добавление трекинговой информации позволяет генератору корректно описывать относительное положение игроков, зоны прессинга и направления движения мяча.

Для данной работы это направление пока остаётся за рамками основного прототипа: StatsBomb предоставляет координаты отдельных событий, но не непрерывный трекинг. Тем не менее описанный подход задаёт возможное направление расширения: при наличии трекинговых данных систему можно дополнить более точными пространственными описаниями, не меняя общую архитектуру.

2.9 Обзорные работы и индустриальный контекст

Обзор [24] систематизирует задачи, датасеты и методы автоматической генерации игровых комментариев: от шахмат и го до футбола и киберспорта. Авторы выделяют несколько сквозных проблем: отсутствие унифицированных метрик оценки, сложность выравнивания комментария с событиями, ограни-

ченное количество качественных датасетов. Обзор подтверждает, что задача генерации комментариев по событийным данным является самостоятельным направлением с устойчивым корпусом работ, а не вспомогательной задачей компьютерного зрения.

С практической стороны интерес представляет опыт индустриальных систем [25]. Реальные продукты для автоматического комментирования матчей строятся на многослойных пайплайнах: ингестия событий, фильтрация по значимости, формирование контекста, генерация текста и постпроверка. Простая подача сырых данных напрямую в языковую модель в промышленных системах не используется именно потому, что это даёт нестабильный и трудно воспроизводимый результат. Этот опыт подтверждает архитектурные решения, принятые в данной работе.

2.10 Ограничения и вклад настоящей работы

Анализ литературы выявляет несколько устойчивых ограничений, характерных для большинства существующих работ.

Во-первых, практически все исследования ориентированы на англоязычные данные. Русскоязычные футбольные комментарии — это отдельный жанр с собственной лексикой, стилистикой и языковыми нормами. Готовых размеченных данных для русского языка практически нет, а результаты, полученные на английских датасетах, нельзя переносить напрямую.

Во-вторых, многие исследования по комментированию матчей де-факто предполагают наличие видеопотока или как минимум трекинговых данных высокого разрешения. Задача, сформулированная только на основе event JSON, решается значительно реже — хотя, как показывает ряд работ [7, 13, 19], именно такая постановка вполне осмысленна и практически реализуема.

В-третьих, в большинстве работ значительный акцент делается на качестве генеративной модели, тогда как предобработка входа — стандартизация

координат, фильтрация событий, построение окон — остаётся в тени или описывается кратко. Между тем именно эти этапы во многом определяют практическое качество системы.

Настоящая работа закрывает эти пробелы применительно к конкретному сценарию: русскоязычный тифлокомментарий по данным StatsBomb JSON, без видео, с акцентом на надёжную предобработку и структурированное формирование контекста.

3 Данные и предобработка

3.1 Источник данных

В экспериментах используются все 51 матча Евро-2024 из StatsBomb Open Data. Для каждого матча доступны события `events` и при наличии данные StatsBomb 360. Отдельно выделяется подмножество матчей для финальной генерации и озвучивания: матч открытия Германия — Шотландия и матчи финальной стадии.

Единицей исходных данных является одно футбольное событие. Это JSON-запись, в которой указано, когда произошло действие, какая команда и игрок участвовали, где находился мяч на поле и какой был исход действия. Например, для передачи в данных есть начальная координата `location`, конечная координата `pass.end_location`, получатель `pass.recipient`, высота передачи `pass.height` и, если передача неудачна, поле `pass.outcome`. Для ведения мяча аналогично используется `carry.end_location`, для удара — поля внутри `shot`.

Данные StatsBomb 360 задают не новое событие, а дополнительный моментный снимок расположения игроков в тот же момент времени. В нём есть `freeze_frame`: координаты видимых игроков, признаки `teammate`, `actor`, `keeper`, а также `visible_area` — многоугольник видимой области камеры. У части событий 360-данных нет; у части они есть, но могут быть геометрически ошибоч-

ными, поэтому такие кадры дополнительно проверяются.

Таблица 3.1 – Основные поля исходных данных StatsBomb

Блок	Примеры полей	Смысл для задачи
Общие поля события	<code>id</code> , <code>period</code> , <code>timestamp</code> , <code>type.name</code>	Идентификатор, тайм, время и тип действия: пас, удар, ведение, фол и т.д.
Участники	<code>team.name</code> , <code>player.name</code> , <code>pass.recipient.name</code>	Команда, игрок с мячом, адресат передачи.
Координаты	<code>location</code> , <code>pass.end_location</code> , <code>carry.end_location</code>	Начальная и конечная точки действия на поле 120×80 .
Исход действия	<code>pass.outcome</code> , <code>shot.outcome</code> , <code>play_pattern.name</code>	Неудачная передача, аут, офсайд, удар, стандартное положение.
StatsBomb 360	<code>freeze_frame</code> , <code>visible_area</code>	Расстановка игроков и видимая область камеры в момент события.

Компактный пример реального входного JSON приведён в Приложении В. Он показывает, что именно передаётся дальше в пайплайн: исходное событие, 360-контекст и добавленные производные признаки.

3.2 Стандартизация координат и направления атаки

Поле StatsBomb задаётся координатами $x \in [0, 120]$, $y \in [0, 80]$. Ось x идёт от левых ворот к правым, ось y — от верхней бровки к нижней. При этом сама карта поля не поворачивается: левый край всегда остаётся левым краем картинки, правый — правым. Проблема в том, что футбольные команды меняются сторонами после перерыва. Поэтому одно и то же увеличение x может означать для одной команды движение к чужим воротам, а для другой — движение назад к своим.

Чтобы описывать события одинаково для всех матчей, для каждого матча

вручную задаётся *референсная команда* по таймам: команда, для которой в данном тайме известно, какие ворота являются своими. После этого для каждого события определяется:

- где находятся свои ворота команды с мячом: слева или справа;
- где находятся чужие ворота;
- какое направление по оси x является движением вперёд.

Например, если Германия в первом тайме атакует влево, то для событий Германии движение от $x = 70$ к $x = 50$ считается продвижением вперёд, хотя численно координата x уменьшается. Для соперника в этот же момент всё наоборот: движение от $x = 50$ к $x = 70$ будет продвижением к чужим воротам.

Формально это задаётся знаком атаки:

$$s(e) = \begin{cases} 1, & \text{если команда с мячом атакует вправо,} \\ -1, & \text{если команда с мячом атакует влево.} \end{cases} \quad (3.1)$$

Для действия со стартовой координатой x_{start} и конечной координатой x_{end} продвижение к чужим воротам определяется как

$$\Delta_{forward}(e) = s(e) \cdot (x_{end} - x_{start}). \quad (3.2)$$

Если $\Delta_{forward} > 0$, действие продвигает мяч к чужим воротам; если $\Delta_{forward} < 0$, действие направлено назад. Это поле используется и в признаках, и в промпте для LLM.

Отдельно важно различать два вида координат. Для визуализации событий используется стандартизированная карта: эпизод при необходимости разворачивается на 180 градусов, чтобы выбранная референсная логика тайма отображалась одинаково. Для расчёта признаков сохраняется и командная интерпретация: `own_half`, `opponent_half`, `own_box`, `opponent_box`. Благодаря этому модель и LLM получают не просто координаты, а понятные футбольные при-

3.3 Разметка зон поля

Зоны поля

Угловые зоны

Из-за боковой (верх)

Верхний фланг ($y < 18$)

Левая штрафная

Правая штрафная

Левая вратарская

Угол штрафной левый верх

Угол штрафной правый верх

Правая вратарская

Центральный коридор ($18 \leq y \leq 62$)

Центральный круг

Угол штрафной левый низ

Угол штрафной правый низ

Перед штрафной (лев.)

Перед штрафной (прав.)

Нижний фланг ($y > 62$)

Левая половина ($x < 60$)

Из-за боковой (низ)

Правая половина ($x \geq 60$)

Рисунок 3.1 – Разметка зон поля, используемая для признака `zone_label`

3.4 Фильтрация некорректных 360-кадров

20

щает ситуацию, когда визуализация и LLM получают пространственно неверный контекст. На Рисунке 3.2 показан пример корректной визуализации с 360-контекстом, а на Рисунке 3.3 — пример события, для которого 360-контекст отключается из-за геометрического расхождения.




Рисунок 3.2 – Пример корректной визуализации события с StatsBomb 360




Рисунок 3.3 – Пример события с некорректным 360-контекстом, который исключается из payload

3.5 Формирование признаков событий и эпизодов

После стандартизации координат для каждого события и для каждой цепочки строится расширенное признаковое описание. Оно нужно сразу для двух задач: во-первых, для эвристической soft-разметки важности эпизода; во-вторых, для обучения моделей-селекторов, которые воспроизводят решение о том, нужно ли отправлять эпизод в LLM.

Признаки делятся на несколько групп:

- 1) **Структурные признаки цепочки:** число событий, длительность, максимальный и средний временной разрыв между соседними событиями, тип первого и последнего события.
- 2) **Игровые признаки значимости:** наличие удара, отбора, перехвата, потери, фола, офсайда, негативного исхода паса, стандарта.

- 3) **Пространственные признаки:** вход на чужую половину, вход в чужую штрафную, выход из своей штрафной, окончание эпизода перед штрафной, у боковой линии или в угловой зоне.
- 4) **Признаки движения:** продвижение к чужим воротам, движение назад, поперечное смещение, прогрессивное ведение, перевод фланга, максимальный и средний прогресс по направлению атаки.
- 5) **Классы событий:** агрегированные счётчики событий разных семантических групп: `shot`, `transition`, `turnover`, `build_up`, `foul`, `low_signal`, `duel`, `defensive_action`, `set_piece_or_ref`, `meta`, `discipline`.

Итоговый словарь признаков приведён в Приложении [A](#). Такая декомпозиция важна методологически: модель не получает только координаты или только тип события, а видит компактное описание того, насколько эпизод опасен, продвигается ли мяч к воротам, меняется ли зона игры и есть ли в цепочке событие, значимое для комментария.

4 Методология

4.1 Стратегии формирования эпизодов

Одно событие StatsBomb не всегда совпадает с тем, что человек воспринимает как футбольный эпизод. Например, передача обычно связана с приёмом мяча, ведением и следующим действием; удар может сопровождаться блоком или действием вратаря; потеря мяча часто имеет смысл только вместе с предыдущей передачей или ведением. Поэтому перед генерацией комментария события нужно объединить в короткие цепочки, которые далее называются эпизодами или `payloads`.

В работе сравниваются несколько стратегий группировки. Они отвечают на один и тот же вопрос: какие события попадут в один входной JSON для LLM. Сравнение проводится не по качеству текста напрямую, а по промежу-

точным свойствам эпизодов: сколько payloads получится, насколько длинными они будут, сколько в них значимых событий, как распределятся soft-label классы и насколько устойчиво модель-селектор воспроизводит разметку для такой стратегии. После этого лучшая стратегия используется для финального LLM-прогона.

Базовая идея стратегий семейства **related** состоит в том, что матч представляется как граф событий. Каждое событие StatsBomb становится вершиной графа. Если в поле **related_events** события e_i указан идентификатор события e_j , между ними проводится ребро. В реализации ребро рассматривается как неориентированное: если e_i связано с e_j , то оба события считаются соседними независимо от направления ссылки. Это важно, потому что в данных StatsBomb связь может быть записана только у одного из двух событий.

После построения графа события просматриваются в хронологическом порядке. Для очередного ещё не использованного события строится связная компонента: берётся само событие, затем все его соседи по **related_events**, затем соседи этих соседей и так далее. Полученная компонента сортируется по исходному индексу события в матче и рассматривается как первичная цепочка. Например, передача может быть связана с приёмом мяча, приём — с ведением, а ведение — с потерей. Тогда эти четыре события образуют один кандидат в эпизод:

Pass $\rightarrow$ Ball Receipt* $\rightarrow$ Carry $\rightarrow$ Dispossessed.

Однако связанные компоненты могут быть слишком длинными: особенно в позиционных владениях, где события Pass, Ball Receipt*, Carry и Pressure повторяются много раз подряд. Поэтому для практического использования компоненты дополнительно разбиваются на компактные фрагменты. Для нового события e_k проверяются три условия:

$$\text{cut}(e_k) = 1 \iff (|c| \geq N_{max}) \vee (t(e_k) - t(e_{first}) > T_{max}) \vee (t(e_k) - t(e_{prev}) > G_{max}) \quad (4.1)$$

где $|c|$ — число событий в текущем фрагменте, $t(e_{first})$ — время первого события в нём, $t(e_{prev})$ — время предыдущего события. Если выполняется хотя бы одно условие, текущий фрагмент завершается, а событие e_k начинает новый фрагмент. Дополнительная стратегия **related_stop_cap** вводит ещё одно правило: если в текущем фрагменте встречается футбольное стоп-событие, например удар, фол, офсайд, потеря, перехват, вынос или действие вратаря, фрагмент также завершается. Такая граница ближе к логике комментария: у эпизода появляется понятный смысловой итог.

Таблица 4.1 – Стратегии формирования эпизодов из событий StatsBomb

Стратегия	Как формируется эпизод	Что проверяет эксперимент
<code>event_only</code>	Каждое событие становится отдельным payload. Цепочек фактически нет.	Базовый вариант: показывает, что произойдёт, если не объединять события. Даёт много коротких входов и высокую стоимость LLM-прогона.
<code>related_only</code>	События объединяются по полю <code>related_events</code> . Связь рассматривается как двусторонняя: если событие А связано с В, они попадают в один графовый компонент.	Проверяет, достаточно ли встроенных связей StatsBomb для получения смысловых эпизодов. Минус: компоненты могут становиться слишком длинными.
<code>related_cap</code>	Используется тот же граф связанных событий, но цепочка дополнительно режется по максимальному числу событий, длительности и временному разрыву.	Проверяет, помогает ли ограничение длины сделать payload удобнее для LLM и уменьшить риск пересказа слишком длинного фрагмента матча.
<code>related_stop_cap</code>	К стратегии <code>related_cap</code> добавляется разрезание по стоп-событиям: удар, фол, офсайд, потеря, перехват, вынос, действие вратаря.	Проверяет гипотезу, что футбольный эпизод должен завершаться на естественной смысловой границе, а не только по техническому лимиту длины.
<code>time_window</code>	События группируются по фиксированным временным окнам без явной опоры на <code>related_events</code> .	Альтернативный baseline: показывает, насколько хорошо работает простая временная близость без знания связей между событиями.

Для ограниченных стратегий используются параметры:

$$N_{max} = 6, \quad T_{max} = 10 \text{ секунд}, \quad G_{max} = 4 \text{ секунды}, \quad (4.2)$$

где N_{max} — максимальное число событий в эпизоде, T_{max} — максимальная длительность эпизода, G_{max} — максимальный допустимый разрыв между соседними событиями. Параметр G_{max} нужен для защиты от склеивания событий, которые формально оказались в одной связанной компоненте, но в реальном времени уже относятся к разным микрофрагментам игры.

Итоговое сравнение стратегий проводится по четырём группам критериев:

- 1) **Компактность эпизодов:** медианная длина цепочки, квантиль P_{90} по числу событий, средняя и медианная длительность. Длинные цепочки хуже подходят для LLM, потому что модель начинает пересказывать последовательность действий вместо короткого тифлокомментария.
- 2) **Стоимость LLM-прогона:** число payloads, которые придётся отправить в модель. Стратегия `event_only` обычно создаёт слишком много входов, а `related_only` может создавать слишком длинные входы.
- 3) **Распределение soft-labels:** доля классов `skip`, `brief`, `must`. Это показывает, какая часть сформированных эпизодов потенциально требует озвучивания.
- 4) **Качество селектора:** macro-F1, weighted-F1, balanced accuracy и accuracy при предсказании `soft_label_3`. Эти метрики показывают, насколько стабильно признаки эпизода позволяют воспроизвести выбранную методологию отбора.

Таким образом, сравнение стратегий — это сравнение разных способов подготовить вход для LLM. В финальный генеративный этап не отправляется весь поток событий: сначала выбирается стратегия группировки, затем для полученных эпизодов считается soft-label, после чего в LLM отправляются только эпизоды классов `brief` и `must`.

4.2 Soft-разметка важности эпизодов

Готовой ручной разметки того, какие эпизоды футбольного матча нужно озвучивать, в данных нет. Поэтому в работе используется weak supervision: целевая переменная задаётся не экспертной разметкой, а прозрачной эвристикой, построенной на футбольных признаках. Такая разметка называется soft-label, потому что она не является абсолютной истиной, но задаёт согласованное приближение к задаче отбора эпизодов.

Эвристики формировались не только по структуре StatsBomb JSON. Перед фиксацией правил вручную просматривались и анализировались футбольные трансляции Okko с точки зрения того, какие действия комментатор описывает в первую очередь, как часто называется положение мяча, как проговариваются передачи, стандарты, потери, удары и игровые паузы. Этот ручной просмотр использовался как практический ориентир для правил тифлокомментария: комментарий должен быстро отвечать на вопросы «где мяч?», «кто действует?», «что произошло?» и «чем завершился эпизод?». Поэтому в эвристику попали не все события подряд, а именно те, которые создают смысловой итог для слушателя: удары, входы в штрафную, продвижение к воротам, длинные передачи, переводы фланга, перехваты, потери, фолы, офсайды и стандарты. Низкосигнальные события вроде простого приёма мяча или давления без исхода, наоборот, не должны перегружать аудиодорожку.

Для эпизода c вычисляется одно числовое значение важности $S(c)$:

$$\begin{aligned} S(c) = & 3.0 \cdot n_{shot} + 2.5 \cdot n_{box} + 2.0 \cdot n_{high} + 1.5 \cdot n_{longpass} \\ & + 1.2 \cdot n_{forward} + 1.2 \cdot n_{switch} + 1.0 \cdot n_{badpass} + 0.8 \cdot n_{setplay} \\ & - 0.35 \cdot n_{low} - P(c). \end{aligned} \quad (4.3)$$

Здесь все n . — неотрицательные целочисленные счётчики событий внутри эпизода c : n_{shot} — число ударов, n_{box} — число входов в чужую штрафную,

n_{high} — число событий высокой значимости, $n_{longpass}$ — число длинных передач, $n_{forward}$ — число продвижений вперёд, n_{switch} — число переводов фланга, $n_{badpass}$ — число неудачных передач, $n_{setplay}$ — число стандартов, n_{low} — число низкосигнальных событий. Чем длиннее эпизод и чем больше в нём футбольных действий, тем больше потенциальное значение $S(c)$; сверху оно специально не ограничивается, потому что эпизоды могут содержать разное число событий. Снизу score также может быть отрицательным: это означает, что в эпизоде преобладают низкосигнальные или технические действия, которые не нужно озвучивать отдельно.

Отдельный штраф $P(c)$ задаётся как

$$P(c) = 2 \cdot \mathbb{I}\{N(c) = 1, n_{low} = 1\} + 0.5 \cdot \mathbb{I}\{T(c) > 15, n_{shot} = 0\}, \quad (4.4)$$

где $N(c)$ — число событий в цепочке, $T(c)$ — длительность цепочки в секундах, а $\mathbb{I}\{\cdot\}$ — индикатор условия, равный 1, если условие выполнено, и 0 иначе. Поэтому $P(c)$ может принимать значения 0, 0.5, 2 или 2.5. Первый штраф убирает одиночные низкосигнальные события, например отдельный приём мяча или давление без исхода. Второй штраф снижает важность слишком длинных неопасных цепочек: если эпизод длится больше 15 секунд и в нём нет удара, он не должен автоматически становиться важным только из-за длины.

Положительные слагаемые в формуле (4.3) повышают важность эпизода, потому что они соответствуют действиям, которые помогают слушателю понять развитие матча: удар, вход в штрафную, продвижение к воротам, длинная передача, перевод фланга, стандарт или явный неудачный исход. Отрицательные слагаемые нужны для обратной задачи — не перегружать аудиодорожку событиями, которые сами по себе мало что меняют. Поэтому формула одновременно решает две задачи: поднимает приоритет содержательных эпизодов и понижает приоритет технических или слишком растянутых цепочек без опасного итога.

Эта формула не претендует на роль истинной экспертной разметки. Её

задача другая: зафиксировать явные футбольные правила в воспроизводимом виде и получить ргоху-метки для большого числа эпизодов. Поэтому веса задаются не обучением, а экспертной логикой: сначала выделяются действия, которые в реальном комментарии почти нельзя пропустить, затем действия, которые важны только в контексте развития атаки, и, наконец, низкосигнальные события, которые сами по себе не должны перегружать аудиодорожку. Такой подход позволяет прозрачно объяснить, почему эпизод попал или не попал в LLM.

Содержательно веса можно разделить на три уровня. Вес 3.0 для удара означает событие максимального приоритета: удар почти всегда должен быть озвучен. Вес 2.5 для входа в штрафную отражает рост опасности эпизода даже без удара. Веса 1.0–1.5 соответствуют развитию атаки: длинная передача, продвижение вперёд, перевод фланга или неудачный исход паса. Отрицательный вес для n_{low} и штраф $P(c)$ нужны, чтобы цепочки из приёмов мяча и давления без результата не получали высокий приоритет только из-за длины.

Промежуточная пятибалльная шкала y_5 задаётся по порогам score:

$$y_5(c) = \begin{cases} 0, & S(c) \leq 0, \\ 1, & 0 < S(c) \leq 1.5, \\ 2, & 1.5 < S(c) \leq 3.5, \\ 3, & 3.5 < S(c) \leq 6.0, \\ 4, & S(c) > 6.0. \end{cases} \quad (4.5)$$

Содержательно классы интерпретируются так:

Таблица 4.2 – Интерпретация пяти классов эвристической важности

Класс	Название	Смысл
0	шумовой эпизод	Служебное или низкосигнальное действие, которое не нужно озвучивать отдельно.
1	слабый сигнал	Есть минимальное футбольное действие, но без заметного продвижения или исхода. Обычно не отправляется в LLM.
2	умеренный эпизод	Есть развитие владения, переход зоны или действие, которое можно кратко прокомментировать.
3	значимый эпизод	Есть заметное продвижение, стандарт, потеря, перехват или другой смысловой итог. Желательно прокомментировать.
4	обязательный эпизод	Удар, опасная доставка, вход в штрафную, важный исход или комбинация нескольких сильных признаков. Обязательно отправляется в генерацию.

Для практического селектора пятибалльная шкала агрегируется в три класса:

$$y_3(c) = \begin{cases} 0, & y_5(c) \in \{0, 1\} \quad \text{не комментировать,} \\ 1, & y_5(c) \in \{2, 3\} \quad \text{кратко прокомментировать,} \\ 2, & y_5(c) = 4 \quad \text{обязательно комментировать.} \end{cases} \quad (4.6)$$

Именно y_3 используется как основная целевая переменная для моделей отбора и для формирования финальных payloads в LLM: класс 0 отбрасывается, класс 1 получает режим **brief**, класс 2 — режим **must**.

Таким образом, задача моделей отбора формулируется не как обучение «идеальному комментатору», а как обучение селектору, который приближает заданную методологию отбора эпизодов. Это важно для интерпретации резуль-

татов: высокое качество на полном наборе признаков означает, что модель научилась воспроизводить эвристическую разметку, а не доказывает абсолютное качество комментария. Поэтому дополнительно анализируется сокращённый набор признаков без прямых членов формулы и проводится отдельная оценка LLM-ответов.

4.3 Модели отбора эпизодов

Логистическая регрессия и CatBoost в данной работе используются не как самостоятельные генераторы комментариев. Их роль более узкая: это модели-селекторы, которые по признакам эпизода предсказывают, нужно ли отправлять этот эпизод в LLM и в каком режиме: не комментировать, кратко прокомментировать или обязательно прокомментировать. Иными словами, LLM отвечает за текст, а классическая модель отвечает за предварительный отбор эпизодов.

На первый взгляд может показаться, что обучение модели избыточно, поскольку soft-label уже задаётся формулой. Однако формула в этой работе играет роль первичной разметки, а не конечного продукта. Она нужна, чтобы получить воспроизводимые гошу-метки на большом наборе матчей без ручной разметки каждого эпизода. Модели отбора проверяют, можно ли автоматизировать это решение по признаковому описанию эпизода и насколько это описание переносимо между матчами. В дальнейшем та же схема может быть использована с ручной или смешанной разметкой: формула задаёт стартовые метки, а модель дообучается на экспертных оценках.

Такое разделение нужно по двум причинам. Во-первых, отправлять в LLM все события матча дорого и неэффективно: большая часть событий является низкосигнальной и не требует отдельного комментария. Во-вторых, модель-селектор позволяет разделить задачу отбора от задачи генерации. Это делает пайплайн управляемым: можно менять стратегию группировки, порог отбора,

набор признаков и модель селектора, не переписывая промпт и не перегружая LLM лишними событиями.

Логистическая регрессия выбрана как простая линейная базовая модель. Она показывает, насколько задача решается почти линейной комбинацией признаков. CatBoost выбран как более сильная модель для табличных данных: он умеет работать с категориальными признаками, нелинейными взаимодействиями и неоднородными числовыми шкалами. Сравнение этих моделей позволяет понять, есть ли в признаках полезные нелинейные зависимости или достаточно простой линейной схемы.

Перед обучением каждый эпизод переводится в одну строку табличного датасета. Это принципиальный момент: модели не получают полный JSON матча и не генерируют текст. Они получают только агрегированные признаки эпизода и предсказывают класс важности `soft_label_3`. Формат входа для моделей приведён в Таблице [4.3](#).

Таблица 4.3 – Что передавалось в модели отбора CatBoost и LogReg

Компонент	Описание
Наблюдение	Одна строка соответствует одному сформированному эпизоду, то есть одному payload после группировки событий. В основном эксперименте используется стратегия <code>related_stop_cap</code> .
Целевая переменная	<code>soft_label_3</code> : 0 — не комментировать, 1 — кратко прокомментировать, 2 — обязательно прокомментировать. Метка получается из эвристической пятибалльной шкалы <code>soft_label_5</code> .
Числовые признаки	Длина и длительность эпизода, временные разрывы, счётчики классов событий, признаки стандартов, ударов, потерь, продвижения мяча, входа в чужую половину и штрафную, переводов фланга, негативных исходов передач и пространственных переходов.
Категориальные признаки	Тип первого и последнего события, тайм, стадия турнира, начальные и конечные относительные зоны, доминирующий переход зоны и другие дискретные описания структуры эпизода.
Что не передавалось	Сырые JSON целиком, текст комментария, ответ LLM, идентификаторы событий как самостоятельные признаки и целевые поля. В честных режимах также исключались прямые компоненты формулы <code>score</code> .
Разбиение	Train/validation/test формируются по <code>match_id</code> , чтобы события одного матча не попадали одновременно в обучение и тест. Это снижает риск утечки между соседними эпизодами одного матча.
Предобработка	Для LogReg числовые признаки масштабируются, категориальные кодируются. CatBoost получает числовые признаки и категориальные столбцы напрямую через механизм <code>cat_features</code> .

При этом важно избежать самообмана. Поскольку `soft-label` строится по

формуле (4.3), часть признаков одновременно участвует и в разметке, и во входе модели. Если обучать модель на полном наборе признаков, она почти напрямую восстанавливает формулу. Поэтому в эксперименте отдельно проверяется не только «может ли модель повторить формулу», но и «остаётся ли сигнал, если убрать прямые компоненты этой формулы». Для этого используются три набора признаков:

- 1) **full** — все признаки, включая прямые компоненты формулы `score`. Этот режим нужен как `sanity check`: модель должна уметь воспроизвести заданную эвристику.
- 2) **no_exact_score_terms** — из входа убираются прямые компоненты формулы `score`: `class_shot_n`, `entered_opp_box_n`, `high_event_n`, `long_pass_n`, `forward_moves_n`, `switched_flank_n`, `bad_pass_outcome_n`, `set_play_n`, `low_signal_n`, а также `events_n` и `duration_sec`, которые входят в штрафы. Этот режим показывает, можно ли приблизить решение по косвенным признакам.
- 3) **structure_zone_only** — остаются в основном структура эпизода, зоны, движение и типы первого/последнего события. Это всё ещё не `gold`-оценка, но такой набор меньше похож на прямое восстановление формулы и лучше показывает информативность пространственно-структурного описания.

Таким образом, результаты моделей не трактуются как доказательство «истинной» важности эпизодов. Они показывают, насколько предложенная `soft`-разметка воспроизводима по признакам и насколько выбранное признаковое описание достаточно информативно для автоматического селектора. Главная интерпретационная ценность здесь не в почти единичном качестве на **full**, а в сравнении с **no_exact_score_terms** и **structure_zone_only**: именно эти режимы показывают, сохраняется ли полезная информация после удаления прямых членов эвристики.

5 Эксперименты и результаты

5.1 Сравнение стратегий группировки




Рисунок 5.1 – Сравнение стратегий формирования эпизодов по длине цепочек и числу payloads на всех матчах Евро-2024




Рисунок 5.2 – Сравнение стратегий формирования эпизодов для матча Германия — Шотландия

Основной вывод сравнения: стратегия `related_stop_cap` сохраняет связность событий через `related_events`, но дополнительно ограничивает длину

цепочки и завершает эпизод на естественных смысловых границах. Поэтому она выбрана как основная стратегия для финального LLM-прогона.

Таблица 5.1 – Сравнение стратегий группировки и экспертная оценка качества комментариев

Стратегия	Payloads для LLM	P_{50} событий	P_{90} событий	Оценка 1–5
event_only	6056	1	1	2
related_only	1977	4	26	3
related_cap	5307	4	6	4
related_stop_cap	5604	3	6	5
time_window	4163	6	6	3

Payloads для LLM посчитаны для набора матчей, выбранных для озвучивания, после фильтрации класса skip. P_{50} и P_{90} характеризуют длину payloads внутри соответствующей стратегии.

Оценка 1–5 выставлена по ручному просмотру качества комментариев: 1 — непригодно, 5 — наиболее пригодно для финальной озвучки. Отдельный детальный пример для матча Германия — Шотландия показан на Рисунке 5.2.

Таблица 5.1 показывает технические характеристики стратегий и итоговую экспертную оценку качества комментариев. Число payloads относится к набору матчей, отобранных для озвучивания, а квантили P_{50} и P_{90} показывают типичную длину и хвост длинных цепочек внутри стратегии. Отдельно для матча Германия — Шотландия был построен график на Рисунке 5.2; он использовался как подробный ручной sanity-check выбранной стратегии. Вариант event_only оказался слишком атомарным: модель часто комментировала отдельное действие без достаточного контекста, поэтому реплики звучали фрагментарно. В related_only появлялся контекст, но длинный хвост цепочек приводил к пересказу последовательности действий и словам-связкам вроде «затем» или «после этого». Стратегия time_window давала ровные по длине фрагменты, но иногда объединяла независимые действия или разрывала связанные события. related_cap заметно улучшала стабильность за счёт ограничений длины, однако граница эпизода не всегда совпадала с футбольным итогом. Поэтому итоговой выбрана related_stop_cap: она сохраняет связанные

события, ограничивает длину payload и завершает цепочку на смысловой границе — ударе, фоле, офсайде, потере, перехвате, выносе или действии вратаря.

5.2 Распределение soft-labels




Рисунок 5.3 – Распределение классов `soft_label_3` по стратегиям группировки

Распределение классов зависит от стратегии группировки, поскольку `soft-label` назначается не отдельному событию, а эпизоду. Например, `event_only` создаёт много коротких низкосигнальных элементов, тогда как `related_only` формирует более длинные цепочки с большим числом значимых действий.

5.3 Качество моделей отбора

После сравнения стратегий группировки для основного эксперимента с моделями фиксируется стратегия `related_stop_cap`. Это сделано намеренно: иначе в одном сравнении смешивались бы две разные задачи — выбор способа группировки событий и качество модели-селектора. Сначала выбирается способ получить эпизод, затем уже на эпизодах одной структуры сравниваются

признаки и модели, предсказывающие `soft_label_3`.

Для оценки используются accuracy, macro-F1, weighted-F1 и balanced accuracy. Основной метрикой выбрана macro-F1, поскольку классы несбалансированы, а ошибки на редком классе **must** особенно важны для качества озвучки. Accuracy в такой задаче может быть завышена за счёт частого класса, тогда как macro-F1 усредняет качество по классам равномерно.

Таблица 5.2 – Качество моделей отбора эпизодов для разных наборов признаков

Набор признаков	Модель	Split	Macro-F1	Weighted-F1	Balanced Acc.	Accuracy
full	LogReg	val	0.999	0.999	0.999	0.999
full	LogReg	test	0.999	0.999	0.999	0.999
full	CatBoost	val	0.999	1.000	0.999	1.000
full	CatBoost	test	1.000	1.000	1.000	1.000
no_exact_score_terms	LogReg	val	0.813	0.820	0.822	0.822
no_exact_score_terms	LogReg	test	0.815	0.821	0.823	0.823
no_exact_score_terms	CatBoost	val	0.846	0.854	0.853	0.854
no_exact_score_terms	CatBoost	test	0.848	0.856	0.855	0.856
structure_zone_only	LogReg	val	0.801	0.810	0.807	0.811
structure_zone_only	LogReg	test	0.801	0.809	0.807	0.810
structure_zone_only	CatBoost	val	0.840	0.849	0.845	0.848
structure_zone_only	CatBoost	test	0.840	0.848	0.843	0.847

full содержит все признаки; no_exact_score_terms исключает прямые компоненты формулы score; structure_zone_only оставляет в основном структуру эпизода, зоны, движение и типы начала/конца.

Таблица 5.2 показывает, что на наборе full обе модели получают почти единичные значения метрик. Это ожидаемый результат: модель видит признаки, из которых была построена сама soft-разметка, поэтому фактически учится воспроизводить заданную формулу. Такой эксперимент нужен как проверка корректности пайплайна: если на full качество было бы низким, это означало бы ошибку в построении признаков, разбиении данных или целевой переменной.

Более содержательны два следующих режима. В no_exact_score_terms

из входа удаляются прямые компоненты формулы score и штрафов. После этого качество снижается до более реалистичного уровня: на тестовой выборке CatBoost получает макро-F1 около 0.848, логистическая регрессия — около 0.815. Это означает, что часть решения всё ещё восстанавливается по косвенным признакам, но задача уже не сводится к прямому копированию формулы.

В режиме `structure_zone_only` остаются преимущественно структурные и пространственные признаки. Качество дополнительно немного снижается, но остаётся заметно выше случайного уровня: CatBoost на тестовой выборке даёт макро-F1 около 0.840. Это показывает, что зоны поля, направление движения, длительность и типы границ эпизода действительно несут информацию о важности события. При этом такой эксперимент не заменяет ручную gold-разметку: он только демонстрирует, что предложенные признаки способны приближать эвристическую методологию отбора.

5.4 Оценка LLM-комментариев

Для генерации комментариев использовались модели семейства GigaChat-2. Этот выбор был практическим: модель является российской разработкой, хорошо поддерживает русский язык, доступна через API и предоставляет бесплатные или учебные лимиты токенов, что важно для воспроизводимого студенческого эксперимента. В работе LLM рассматривается как генератор текста по уже отобраннным payloads, а не как единственный источник решения о важности эпизода.

Для LLM-ответов оцениваются форматные и содержательные критерии:

- валидность JSON и наличие обязательных полей;
- совпадение временных границ с переданным эпизодом;
- наличие футбольного действия в комментарии;
- отсутствие запрещённых временных связок типа «затем», «потом»;

Таблица 5.3 – Автоматическая оценка LLM-комментариев для стратегии `related_stop_cap`

Метрика	Значение
Число ответов	679
Валидный JSON	1.000
Непустой комментарий	1.000
1–2 предложения	0.999
Есть действие	0.892
Нет запрещённых связей	0.707

Таблица 5.3 относится уже не к сравнению стратегий, а к фактическому прогону выбранной стратегии `related_stop_cap` через LLM. Таким образом, Таблица 5.1 отвечает на вопрос «какую структуру входа выбрать», а Таблица 5.3 — на вопрос «насколько корректно модель отвечает при выбранной структуре входа».

Автоматические метрики не заменяют экспертную оценку качества комментария, но позволяют быстро проверять форматные ошибки: невалидный JSON, пустой комментарий, слишком длинные ответы, отсутствие футбольного действия или нарушение запрета на связки вроде «затем» и «потом». Для содержательной проверки дополнительно используется ручной просмотр комментариев и пользовательская оценка аудиоверсии.

5.5 Пользовательская оценка аудиокomentarиев




Рисунок 5.4 – Результаты пользовательской оценки аудиокomentarиев

Мини-опрос используется как качественная проверка воспринимаемости результата. Участники оценивают комментарий по шкале «отлично» / «нормально» / «плохо» и оставляют свободный комментарий. Отдельно анализируются ответы футбольных болельщиков и участников без регулярного футбольного контекста.

6 Программный прототип

6.1 Структура проекта

Прототип включает набор Jupyter-ноутбуков и вспомогательных модулей:

- пайплайн загрузки и стандартизации матчей Евро-2024;
- модуль визуализации событий и StatsBomb 360;
- эксперименты по группировке цепочек и обучению селектора;
- ноутбук генерации LLM-комментариев через GigaChat API;
- ноутбук сборки аудиодорожки через Silero TTS;

- Streamlit-приложение для просмотра матчевых визуализаций.

6.2 Интерфейс просмотра событий

Streamlit-приложение позволяет выбрать матч, тайм и кадр, после чего отображает стандартизированную визуализацию события: положение актёра, игроков из 360-контекста, видимую область и направление действия. Это использовалось как инструмент валидации координат и отладки `bad_ids`. На главной странице прототипа также размещаются видеофрагмент матча и готовая аудиодорожка тифлокомментария.




Рисунок 6.1 — Главная страница Streamlit-приложения с видеофрагментом и аудиодорожкой




Рисунок 6.2 – Страница просмотра визуализаций событий матча в Streamlit-приложении

6.3 Сборка аудиодорожки

После генерации комментариев JSONL преобразуется в аудио. Для каждой реплики создаётся отдельный WAV-файл, затем комментарии размещаются на дорожке в соответствии с `t_start`. В промежутках без комментариев добавляется тихий фоновый шум. Итогом являются отдельные дорожки по таймам и полный WAV-файл матча.

Для синтеза речи выбран Silero TTS: это открытая русскоязычная TTS-модель, которую можно запускать локально или в Kaggle без отдельного коммерческого сервиса. Для задачи футбольного аудиоописания важна также возможность управлять темпом речи: комментарии можно ускорять, чтобы реплика помещалась в короткое окно между игровыми событиями и не перекрывала следующий эпизод.

7 Заключение

В работе разработан прототип системы генерации русскоязычных тифлокомментариев по футбольным событиям StatsBomb. Реализованы стандартизация координат с учётом таймов, фильтрация некорректных 360-кадров, несколько стратегий группировки событий, эвристическая soft-разметка важности эпизодов, модели отбора, LLM-генерация комментариев и сборка аудиодорожки.

Эксперименты показали, что качество комментария существенно зависит от стратегии формирования эпизодов. Наиболее практичной оказалась стратегия `related_stop_cap`, совмещающая связность `related_events` с ограничением длины и естественными стоп-событиями. Такой подход уменьшает риск длинных перегруженных payloads и делает вход для LLM более стабильным.

Ограничения работы связаны с отсутствием полноценной gold-разметки тифлокомментариев, использованием эвристических soft-labels и ограниченным пользовательским тестированием. В дальнейшем систему можно улучшить за счёт ручной разметки подвыборки эпизодов, LLM-as-a-judge оценки, расширения TTS-пайплайна и интеграции трекингowych данных при их наличии.

Список литературы

- [1] FIFA. *Audio description commentary marks yet another milestone for the most inclusive club tournament ever*. 2025. URL: <https://vod.fifa.com/news/audio-description-commentary-milestone-most-inclusive-club-tournament-ever> (дата обр. 12 мая 2026).
- [2] UEFA. *Giving blind football fans a better service*. 2018. URL: <https://www.uefa.com/news-media/news/0242-0f8e5d13a4dd-86d56b8137ca-1000--giving-blind-football-fans-a-better-service/> (дата обр. 12 мая 2026).
- [3] Особый взгляд. «Особый взгляд» получил патент на приложение для тифлокомментирования. 2025. URL: <https://specialviewportal.ru/news/technologies/osobyu-vzglyad-poluchil-patent-na-prilozhenie-dlya-tiflokommentirovaniya/> (дата обр. 12 мая 2026).
- [4] Павел Обиух. *Услышать футбол: как тифлокомментируют матчи в России*. 2024. URL: <https://specialviewportal.ru/articles/sport/articles2007/> (дата обр. 12 мая 2026).
- [5] Rakas.sport. *Тифлокомментарий: что это такое, кому это нужно и кто это делает*. 2024. URL: <https://www.sports.ru/football/blogs/3268020.html> (дата обр. 12 мая 2026).
- [6] Okko. *В честь Международного дня слепых Okko покажет футбол с дескриптивными комментариями*. 2025. URL: <https://blog.okko.tv/news/v-chest-mezhdunarodnogo-dnya-slepykh-okko-pokazhet-futbol-s-deskriptivnymi-kommentariyami-13-11-2025> (дата обр. 12 мая 2026).
- [7] Ze Wang и Naoki Yoshinaga. “Commentary Generation from Data Records of Multiplayer Strategy Esports Game”. В: *arXiv preprint* (2022). URL: <https://arxiv.org/abs/2212.10935> (дата обр. 11 апр. 2026).

- [8] Racing Authors. “Generating Racing Game Commentary from Vision, Language, and Structured Data”. В: *Proceedings of INLG*. 2021. URL: <https://aclanthology.org/> (дата обр. 11 апр. 2026).
- [9] Jianmin Zhang, Jingang Yao и Xiaojun Wan. “Towards Constructing Sports News from Live Text Commentary”. В: *Proceedings of ACL*. 2016. URL: <https://aclanthology.org/P16-1129/> (дата обр. 11 апр. 2026).
- [10] Lin Chen и др. “Content Selection for Real-time Sports News Construction from Live Text Commentary”. В: *Proceedings of ACL*. 2017. URL: <https://aclanthology.org/> (дата обр. 11 апр. 2026).
- [11] Wei Xu и др. “SportsSum2.0: Generating High-Quality Sports News from Live Text Commentary”. В: *arXiv preprint* (2021). URL: <https://arxiv.org/abs/2110.05750> (дата обр. 11 апр. 2026).
- [12] Kuan-Hao Huang, Chen Li и Kai-Wei Chang. “Generating Sports News from Live Commentary: A Chinese Dataset for Sports Game Summarization”. В: *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*. 2020, с. 609—615. URL: <https://aclanthology.org/2020.aacl-main.61/> (дата обр. 12 мая 2026).
- [13] LFC Authors. “Live Football Commentary (LFC): A Large-Scale Dataset for Building Football Commentary Generation Models”. В: *Proceedings of INLG*. 2025. URL: <https://aclanthology.org/> (дата обр. 11 апр. 2026).
- [14] Ehud Reiter и Robert Dale. *Building Natural Language Generation Systems*. Cambridge University Press, 2000. URL: <https://www.cambridge.org/core/books/building-natural-language-generation-systems/> (дата обр. 11 апр. 2026).
- [15] Albert Gatt и Emiel Krahmer. “Survey of the State of the Art in Natural Language Generation: Core Tasks, Applications and Evaluation”. В: *Journal*

- of Artificial Intelligence Research* (2018). URL: <https://jair.org/index.php/jair/article/view/11173> (дата обр. 11 апр. 2026).
- [16] SoccerNet Authors. “SoccerNet-Echoes: A Soccer Game Audio Commentary Dataset”. B: *arXiv preprint* (2024). URL: <https://arxiv.org/abs/2405.07354> (дата обр. 11 апр. 2026).
- [17] StatsBomb. *StatsBomb Open Data*. Official repository and documentation. 2026. URL: <https://github.com/statsbomb/open-data> (дата обр. 11 апр. 2026).
- [18] Socceraction. *StatsBomb Event Schema*. Documentation. 2026. URL: <https://socceraction.readthedocs.io/> (дата обр. 11 апр. 2026).
- [19] MatchTime Authors. “Towards Automatic Soccer Game Commentary Generation”. B: *Proceedings of EMNLP*. 2024. URL: <https://aclanthology.org/> (дата обр. 11 апр. 2026).
- [20] MatchVoice Authors. “Commentary Generation for Soccer Highlights”. B: *arXiv preprint* (2025). URL: <https://arxiv.org/abs/2508.07543> (дата обр. 11 апр. 2026).
- [21] Vision Authors. “Towards Automatic Soccer Commentary Generation with Knowledge-Enhanced Visual Reasoning”. B: *arXiv preprint* (2026). URL: <https://arxiv.org/abs/2604.00057> (дата обр. 11 апр. 2026).
- [22] Lipisha Chaudhary, Trisha Mittal, Subhadra Gopalakrishnan, Ifeoma Nwogu и Jaclyn Pytlarz. *MCAD: Multimodal Context-Aware Audio Description Generation For Soccer*. 2025. arXiv: [2511.09448](https://arxiv.org/abs/2511.09448) [cs.MM]. URL: <https://arxiv.org/abs/2511.09448> (дата обр. 12 мая 2026).
- [23] Tracking Authors. “Player Tracking-Integrated Soccer Game Commentary Generation”. B: *IJSAT* (2025). URL: <https://example.com/tracking-commentary> (дата обр. 11 апр. 2026).

- [24] AIGCC Survey Authors. “AI-Generated Game Commentary: A Survey and a Datasheet”. В: *arXiv preprint* (2025). URL: <https://arxiv.org/abs/2506.17294> (дата обр. 11 апр. 2026).
- [25] Industry Review. “AI Sports Commentary Generation: 20 Advances”. В: *Industry review* (2026). URL: <https://example.com/industry-review> (дата обр. 11 апр. 2026).

А Словарь признаков

В таблице ниже приведены признаки, сформированные после стандартизации событий и используемые для soft-разметки и обучения моделей отбора. Признаки с типом **target** не передаются в модель как входные переменные, а используются как целевые метки.

Таблица А.1 – Итоговый словарь признаков эпизода

Группа	Признак	Тип	Как рассчитывается и зачем нужен
Структура эпизода	<code>duration_sec</code>	числовой	Разность времени последнего и первого события.
Структура эпизода	<code>events_n</code>	числовой	Количество событий внутри цепочки.
Структура эпизода	<code>first_type</code>	категориальный	Тип первого события в цепочке.
Структура эпизода	<code>last_type</code>	категориальный	Тип последнего события в цепочке.
Структура эпизода	<code>max_gap_sec</code>	числовой	Максимальный временной разрыв между соседними событиями.
Структура эпизода	<code>mean_gap_sec</code>	числовой	Средний временной разрыв между соседними событиями.
Структура эпизода	<code>period</code>	категориальный	Тайм первого события цепочки.
Структура эпизода	<code>stage</code>	категориальный	Стадия турнира из метаданных матча.
Типы событий	<code>class_build_up_n</code>	числовой	Количество событий, отнесённых к семантическому классу <code>build_up</code> .
Типы событий	<code>class_defensive_action_n</code>	числовой	Количество событий, отнесённых к семантическому классу <code>defensive_action</code> .
Типы событий	<code>class_discipline_n</code>	числовой	Количество событий, отнесённых к семантическому классу <code>discipline</code> .
Типы событий	<code>class_duel_n</code>	числовой	Количество событий, отнесённых к семантическому классу <code>duel</code> .
Типы событий	<code>class_foul_n</code>	числовой	Количество событий, отнесённых к семантическому классу <code>foul</code> .
Типы событий	<code>class_low_signal_n</code>	числовой	Количество событий, отнесённых к семантическому классу <code>low_signal</code> .
Типы событий	<code>class_meta_n</code>	числовой	Количество событий, отнесённых к семантическому классу <code>meta</code> .
Типы событий	<code>class_set_piece_or_ref_n</code>	числовой	Количество событий, отнесённых к семантическому классу <code>set_piece_or_ref</code> .
Типы событий	<code>class_shot_n</code>	числовой	Количество событий, отнесённых к семантическому классу <code>shot</code> .
Типы событий	<code>class_transition_n</code>	числовой	Количество событий, отнесённых к семантическому классу <code>transition</code> .
Типы событий	<code>class_turnover_n</code>	числовой	Количество событий, отнесённых к семантическому классу <code>turnover</code> .
Типы событий	<code>high_event_n</code>	числовой	Счётчик событий высокой значимости: удар, фол, офсайд, перехват, подбор, потеря и т.д.
Типы событий	<code>low_signal_n</code>	числовой	Счётчик низкосигнальных событий <code>Ball Receipt*</code> и <code>Pressure</code> .
Типы событий	<code>set_play_n</code>	числовой	Счётчик событий со стандартным <code>play_pattern</code> : аут, штрафной, угловой, удар от ворот, <code>kickoff</code> .
Зоны поля	<code>center_circle_touch_n</code>	числовой	Сколько событий произошло в центральном круге.
Зоны поля	<code>corner_zone_end_n</code>	числовой	Сколько действий закончилось в угловой зоне.
Зоны поля	<code>ended_final_third_n</code>	числовой	Сколько действий завершилось в финальной трети атаки.
Зоны поля	<code>entered_opp_box_n</code>	числовой	Сколько раз действие вошло в чужую штрафную.
Зоны поля	<code>entered_opp_half_n</code>	числовой	Сколько раз конечная зона события перешла на чужую половину.

Группа	Признак	Тип	Как рассчитывается и зачем нужен
Зоны поля	left_own_box_n	числовой	Сколько раз действие вывело мяч из своей штрафной.
Зоны поля	pre_box_end_n	числовой	Сколько действий закончилось перед штрафной.
Зоны поля	third_transition_n	числовой	Сколько действий перевело мяч между третями поля.
Зоны поля	throwin_end_n	числовой	Сколько действий закончилось у верхней или нижней бровки.
Движение мяча	backward_moves_n	числовой	Счётчик действий назад к своим воротам.
Движение мяча	forward_moves_n	числовой	Счётчик действий с положительным продвижением к чужим воротам.
Движение мяча	lateral_moves_n	числовой	Счётчик поперечных или фланговых перемещений.
Движение мяча	long_pass_n	числовой	Число передач, длина которых превышает порог длинной передачи.
Движение мяча	max_forward_delta	числовой	Максимальное продвижение к чужим воротам в одном действии цепочки.
Движение мяча	mean_abs_lateral_delta	числовой	Среднее абсолютное поперечное смещение мяча.
Движение мяча	mean_forward_delta	числовой	Среднее продвижение к чужим воротам по событиям цепочки.
Движение мяча	progressive_carry_n	числовой	Число введений мяча с заметным продвижением вперёд.
Движение мяча	switched_flank_n	числовой	Число действий, переведших мяч из одного флангового коридора в другой.
Исход действия	bad_pass_outcome_n	числовой	Число передач с негативным outcome: Incomplete, Out, Pass Offside, Unknown.
Целевая метка	soft_label_3	target	Агрегация soft_label_5 в skip / brief / must.
Целевая метка	soft_label_5	target	Пятиуровневая эвристическая важность по формуле score.

В Примеры JSON-payloads для LLM

В этом приложении приведены сокращённые примеры структур, которые используются в пайплайне. Полные JSON-файлы слишком объёмные для включения в текст работы, поэтому ниже оставлены только поля, важные для понимания методологии.

В этом приложении показан один и тот же эпизод на разных стадиях обработки. Пример взят из реального файла `llm_payloads_speak_set_related_stop_cap` матч Германия — Шотландия, стратегия `related_stop_cap`. В листингах не показаны все поля JSON, а оставлены только те, которые важны для понимания пайплайна.

Листинг 1: Фрагмент исходного события StatsBomb до очистки

```
{
  "id": "df6f6fb7-f0b0-4561-9171-f4172f5e97e7",
  "index": 5,
  "period": 1,
  "timestamp": "00:00:01.191",
  "minute": 0,
  "second": 1,
  "type": {
    "id": 30,
    "name": "Pass"
  },
  "play_pattern": {
    "id": 9,
    "name": "From Kick Off"
  },
  "team": {
    "id": 770,
    "name": "Germany"
  },
  "player": {
```

```
"id": 8966,
"name": "Kai Havertz"
},
"position": {
  "id": 23,
  "name": "Center Forward"
},
"location": [
  61.0,
  40.1
],
"duration": 1.234945,
"related_events": [
  "f9195e75-1617-478c-bf9d-66f17151724a"
],
"pass": {
  "recipient": {
    "id": 12407,
    "name": "Maximilian Mittelst\u00e4dt"
  },
  "length": 18.603764,
  "angle": -2.4475427,
  "height": {
    "id": 1,
    "name": "Ground Pass"
  },
  "end_location": [
    46.7,
    28.2
  ],
  "body_part": {
    "id": 38,
    "name": "Left Foot"
  },
  "type": {
```

```
    "id": 65,  
    "name": "Kick Off"  
  }  
}  
}
```

Листинг 2: То же событие после стандартизации и очистки полей

```
{  
  "id": "df6f6fb7-f0b0-4561-9171-f4172f5e97e7",  
  "index": 5,  
  "period": 1,  
  "timestamp": "00:00:01.191",  
  "minute": 0,  
  "second": 1,  
  "type": {  
    "name": "Pass"  
  },  
  "play_pattern": {  
    "name": "From Kick Off"  
  },  
  "team": {  
    "name": "Germany"  
  },  
  "player": {  
    "id": 8966,  
    "name": "Havertz",  
    "jersey_number": 7  
  },  
  "position": {  
    "name": "Center Forward"  
  },  
  "location": [  
    59.0,  
    39.9  
  ],  
}
```

```

"duration": 1.234945,
"related_events": [
  "f9195e75-1617-478c-bf9d-66f17151724a"
],
"_flip180": true,
"_reference_team": "Scotland",
"pass": {
  "recipient": {
    "name": "Mittelst\u00e4dt"
  },
  "length": 18.603764,
  "height": {
    "name": "Ground Pass"
  },
  "end_location": [
    73.3,
    51.8
  ],
  "body_part": {
    "name": "Left Foot"
  },
  "type": {
    "name": "Kick Off"
  }
}
}

```

Листинг 3: Добавленные производные признаки для события

```

{
  "quality_flags": {
    "sb360_is_bad_filtered": 0,
    "skip_derive": 0,
    "skip_reason": null
  },
  "event_semantics": {

```

```

    "event_type": "Pass",
    "is_non_play": 0,
    "is_low_signal": 0,
    "is_key_action": 1
},
"orientation": {
    "period": 1,
    "team": "Germany",
    "own_goal_x": 120.0,
    "opp_goal_x": 0.0,
    "attack_sign": -1
},
"zones": {
    "start_abs": "center_circle_zone",
    "end_abs": "right_half:center_lane",
    "start_rel": "center_line",
    "end_rel": "own_half",
    "start_lane": "center_lane",
    "end_lane": "center_lane",
    "zone_transition": "center_line->own_half"
},
"movement": {
    "dx": 14.299999999999997,
    "dy": 11.899999999999999,
    "forward_delta": -14.299999999999997,
    "lateral_delta": 11.899999999999999,
    "label": "backward",
    "compass": "backward_left"
},
"episode_signals": {
    "is_long_pass": 0,
    "pass_length": 18.603764,
    "pass_style_ru": "\u043d\u0438\u0437\u043e\u043c",
    "pass_height_name": "Ground Pass",
    "pass_recipient": "Mittelst\u00e4dt",

```

```

    "pass_direction_compass": "backward_left",
    "pass_target_abs": "right_half:center_lane",
    "pass_target_rel": "own_half",
    "switched_flank": 0,
    "entered_opponent_half": 0,
    "entered_opponent_box": 0
  }
}

```

Листинг 4: Фрагмент реального payload эпизода для LLM

```

{
  "match_id": "3930158",
  "strategy": "related_stop_cap",
  "chain_event_ids": [
    "df6f6fb7-f0b0-4561-9171-f4172f5e97e7",
    "f9195e75-1617-478c-bf9d-66f17151724a",
    "65072c25-9c61-441e-a51c-52856c51ca94",
    "01be895c-5835-4a8d-b99f-2a642f5d26dc"
  ],
  "selection": {
    "soft_label_5": 4,
    "soft_label_3": 2,
    "commenting_mode": "must"
  },
  "chain_features": {
    "events_n": 4,
    "high_events_n": 0,
    "set_play_events_n": 4,
    "low_events_n": 1,
    "entered_opponent_box_n": 0,
    "importance_score_rule": 3
  },
  "events": [
    {
      "event_json": {

```

```
"id": "df6f6fb7-f0b0-4561-9171-f4172f5e97e7",
"index": 5,
"period": 1,
"timestamp": "00:00:01.191",
"minute": 0,
"second": 1,
"type": {
  "name": "Pass"
},
"play_pattern": {
  "name": "From Kick Off"
},
"team": {
  "name": "Germany"
},
"player": {
  "id": 8966,
  "name": "Havertz",
  "jersey_number": 7
},
"position": {
  "name": "Center Forward"
},
"location": [
  59.0,
  39.9
],
"duration": 1.234945,
"related_events": [
  "f9195e75-1617-478c-bf9d-66f17151724a"
],
"_flip180": true,
"_reference_team": "Scotland",
"pass": {
  "recipient": {
```

```

        "name": "Mittelst\u00e4dt"
    },
    "length": 18.603764,
    "height": {
        "name": "Ground Pass"
    },
    "end_location": [
        73.3,
        51.8
    ],
    "body_part": {
        "name": "Left Foot"
    },
    "type": {
        "name": "Kick Off"
    }
}
},
"sb360_summary": {
    "freeze_frame_n": 20,
    "teammates_n": 10,
    "opponents_n": 10,
    "keepers_n": 0,
    "visible_area_points_n": 7
},
"derived": {
    "quality_flags": {
        "sb360_is_bad_filtered": 0,
        "skip_derive": 0,
        "skip_reason": null
    },
    "event_semantics": {
        "event_type": "Pass",
        "is_non_play": 0,
        "is_low_signal": 0,

```



```

    "is_key_action": 1
  },
  "orientation": {
    "period": 1,
    "team": "Germany",
    "own_goal_x": 120.0,
    "opp_goal_x": 0.0,
    "attack_sign": -1
  },
  "zones": {
    "start_abs": "center_circle_zone",
    "end_abs": "right_half:center_lane",
    "start_rel": "center_line",
    "end_rel": "own_half",
    "start_lane": "center_lane",
    "end_lane": "center_lane",
    "zone_transition": "center_line->own_half"
  },
  "movement": {
    "dx": 14.299999999999997,
    "dy": 11.899999999999999,
    "forward_delta": -14.299999999999997,
    "lateral_delta": 11.899999999999999,
    "label": "backward",
    "compass": "backward_left"
  },
  "episode_signals": {
    "is_long_pass": 0,
    "pass_length": 18.603764,
    "pass_style_ru": "\u043d\u0438\u0437\u043e\u043c",
    "pass_height_name": "Ground Pass",
    "pass_recipient": "Mittelst\u00e4dt",
    "pass_direction_compass": "backward_left",
    "pass_target_abs": "right_half:center_lane",
    "pass_target_rel": "own_half",

```

```

        "switched_flank": 0,
        "entered_opponent_half": 0,
        "entered_opponent_box": 0
    }
}
},
{
    "event_json": {
        "id": "f9195e75-1617-478c-bf9d-66f17151724a",
        "index": 6,
        "period": 1,
        "timestamp": "00:00:02.426",
        "minute": 0,
        "second": 2,
        "type": {
            "name": "Ball Receipt*"
        },
        "play_pattern": {
            "name": "From Kick Off"
        },
        "team": {
            "name": "Germany"
        },
        "player": {
            "id": 12407,
            "name": "Mittelst\u00e4dt",
            "jersey_number": 18
        },
        "position": {
            "name": "Left Back"
        },
        "location": [
            73.3,
            51.8
        ],

```

```

    "related_events": [
        "df6f6fb7-f0b0-4561-9171-f4172f5e97e7"
    ],
    "_flip180": true,
    "_reference_team": "Scotland"
},
"sb360_summary": {
    "freeze_frame_n": 20,
    "teammates_n": 10,
    "opponents_n": 10,
    "keepers_n": 0,
    "visible_area_points_n": 6
},
"derived": {
    "quality_flags": {
        "sb360_is_bad_filtered": 0,
        "skip_derive": 0,
        "skip_reason": null
    },
    "event_semantics": {
        "event_type": "Ball Receipt*",
        "is_non_play": 0,
        "is_low_signal": 1,
        "is_key_action": 0
    },
    "orientation": {
        "period": 1,
        "team": "Germany",
        "own_goal_x": 120.0,
        "opp_goal_x": 0.0,
        "attack_sign": -1
    },
    "zones": {
        "start_abs": "right_half:center_lane",
        "end_abs": null,

```

```

        "start_rel": "own_half",
        "end_rel": null,
        "start_lane": "center_lane",
        "end_lane": null,
        "zone_transition": null
    },
    "movement": {
        "dx": null,
        "dy": null,
        "forward_delta": null,
        "lateral_delta": null,
        "label": "unknown",
        "compass": "unknown"
    },
    "episode_signals": {
        "is_long_pass": 0,
        "pass_length": null,
        "pass_style_ru": null,
        "pass_height_name": null,
        "pass_recipient": null,
        "pass_direction_compass": null,
        "pass_target_abs": null,
        "pass_target_rel": null,
        "switched_flank": 1,
        "entered_opponent_half": 0,
        "entered_opponent_box": 0
    }
}
]
}

```

Смысл преобразования следующий. Исходный StatsBomb JSON содержит подробное описание одного действия, но в нём много полей, которые не нужны

для генерации комментария. После очистки остаются факты, которые можно безопасно передать модели: время, команда, игрок, тип действия, координаты и исход. Затем добавляется блок `derived`: он не берётся из StatsBomb напрямую, а рассчитывается в работе. Именно в нём появляются направление атаки, относительные зоны поля, движение вперёд или назад, признаки длинной передачи, перевода фланга и входа в опасную зону. Финальный `payload` объединяет несколько связанных событий в эпизод, добавляет агрегированные признаки цепочки и режим комментирования.

С Системный промпт для генерации комментариев

В этом приложении приведён системный промпт, который использовался для генерации русскоязычных тифлокомментариев по выбранным `payloads`.

Таблица С.1 – Структура системного промпта для LLM-комментатора

Блок промпта	Содержание инструкции
Роль модели	Модель задаётся как тифлокомментатор футбольного матча для незрячего слушателя. Ответ должен быть только на русском языке.
Входной JSON	Объясняется, что на вход передаётся не весь матч, а один выбранный <code>payload</code> : <code>match_id</code> , <code>strategy</code> , <code>chain_event_ids</code> , <code>chain_features</code> , <code>selection</code> , список <code>events</code> .

Блок промпта	Содержание инструкции
Решение отбора	Поле <code>selection.soft_label_3</code> интерпретируется как режим комментария: brief — кратко прокомментировать, must — обязательно отразить главное действие. Модель не должна объяснять <code>soft-label</code> или <code>score</code> в ответе.
Поля события	Модели перечисляются ключевые поля <code>event_json</code> : время, тайм, тип события, команда, игрок, координаты, данные паса, ведения, удара, действия вратаря и стандарта.
Производные признаки	Объясняются <code>derived.orientation</code> , <code>derived.movement</code> , <code>derived.zones</code> , <code>derived.episode_signals</code> . Отдельно указано, что движение «вперёд» и «назад» определяется относительно команды с мячом.
Стиль	Только настоящее время, нейтральный стиль, без местоимений «мы», «они», без эмоций и оценочных слов. Для brief — одно короткое предложение, для must — одно или максимум два предложения.
Запрещённые связи	Запрещены слова «затем», «потом», «после этого», «далее», «в итоге», «следом», «сначала», чтобы ответ звучал как live-комментарий, а не пересказ цепочки.
Приоритет действий	В первую очередь описываются удары, голы, сейвы, блоки, перехваты, потери, фолы, офсайды, стандарты и явное продвижение атаки. Низкосигнальные события Ball Receipt* и Pressure не должны становиться главным содержанием сами по себе.

Блок промпта	Содержание инструкции
Правила по типам	Отдельно заданы правила для <code>Pass</code> , <code>Carry</code> , <code>Shot</code> , <code>Goal Keeper</code> , <code>Block</code> , оборонительных действий, фолов, офсайдов и стандартов. Для паса требуется учитывать получателя, высоту, направление, целевую зону и негативный исход.
StatsBomb 360	360-контекст трактуется как моментный <code>freeze-frame</code> , а не видео. Его можно использовать только для простых фактов вроде давления или плотности игроков; имена и номера игроков из 360 придумывать нельзя.
Формат ответа	Требуется строго валидный JSON с полями <code>t_start</code> , <code>t_end</code> , <code>commentary</code> , <code>commented_event_ids</code> , <code>commented_event_types</code> .

Ниже приведена краткая версия ключевой инструкции, использованной в системном промпте:

Ты — тифлокомментатор футбольного матча для незрячего слушателя. Тебе передаётся один JSON `payload` футбольного эпизода. Эпизод уже выбран системой отбора; твоя задача — не решать, нужно ли его комментировать, а кратко и фактически правильно озвучить выбранный эпизод. Отвечай только на русском языке, в настоящем времени, нейтрально, без слов «затем», «потом», «после этого». Используй только факты из `event_json` и готовые интерпретации из `derived`. Если `payload` попал к тебе, его нужно прокомментировать. Верни строго валидный JSON без текста вне JSON.

D Пример ответа LLM

Ниже приведён пример ответа модели GigaChat-2-Pro для одного payload матча Германия — Шотландия. В основной пайплайн дальше передаются поля времени и текст комментария.

Таблица D.1 – Пример JSON-ответа модели после генерации комментария

Поле	Значение
<code>t_start</code>	00:00:07.397
<code>t_end</code>	00:00:07.871
<code>commentary</code>	Хавертц делает пас низом после начального удара, но МакГрегор не может восстановить владение.

В полном JSONL-файле этот ответ хранится вместе с технической информацией о стратегии группировки, номере payload, модели и статусе парсинга. Для сборки аудиодорожки используются прежде всего три поля: начало реплики, конец связанного эпизода и сам текст комментария.

E Материалы ручного анализа тифлокомментариев

При формировании правил комментирования дополнительно просматривались спортивные трансляции с тифлокомментариями. Ниже приведён пример экрана Окко, использованный как ориентир для анализа пользовательского сценария.




Рисунок Е.1 – Пример спортивной трансляции с тифлокомментарием в Окко